

INFORME DE ANÁLISIS

Reto 8 — Aplicación de técnicas de Data Mining

El Mercado de las Especies de Dataclysm

Autora: Judit Giravent
Fecha: 09/2026
Herramientas: Python 3.13 · pandas · scikit-learn · matplotlib · seaborn
Dataset: Wholesale Customers (UCI ML Repository)

Índice

- 1. Resumen ejecutivo
- 2. Introducción y contexto
- 3. Paso 1: Selección del dataset
- 4. Paso 2: Importación y exploración
- 5. Paso 3: Preparación de datos
- 6. Paso 4: Aplicación de técnicas de Data Mining
- 7. Paso 5: Evaluación de modelos
- 8. Paso 6: Interpretación y visualización
- 9. Conclusiones y recomendaciones
- 10. Anexos

1. Resumen ejecutivo

Este proyecto aplica **técnicas avanzadas de Data Mining** sobre el dataset **Wholesale Customers** de UCI para extraer insights del comportamiento de 440 clientes mayoristas.

Técnicas aplicadas

#	Técnica	Algoritmo	Objetivo	Resultado
1	Clustering	K-means	Segmentar clientes	Silhouette = 0.3953
2	Clasificación	Árbol de decisión	Predecir canal	F1 = 0.9468
3	Regresión	Regresión lineal	Predecir Grocery	R² = 0.7797

Hallazgos principales

- 1. **3 segmentos de clientes:** Fresh alto (restaurantes), Grocery alto (tiendas), pequeños.

2. **Detergents_Paper** es la variable clave para predecir el canal (79,6% importancia).
3. **El canal Retail** compra mucho más detergente que el Horeca.
4. **71,6% de clientes** son pequeños y aportan poco valor.

2. Introducción y contexto

2.1 Contexto narrativo

En Dataclysm, el **Mentor de Datos** enseña al navegante técnicas avanzadas para descubrir patrones ocultos en los datos comerciales.

2.2 Objetivo del reto

Aplicar técnicas de Data Mining (clustering, clasificación, regresión) para extraer insights valiosos que permitan a los mercaderes tomar decisiones estratégicas.

2.3 Metodología

Sigue los 6 pasos oficiales del reto: selección, importación, preparación, técnicas, evaluación e interpretación.

3. Paso 1: Selección del dataset

- **Nombre:** Wholesale Customers
- **Fuente:** UCI Machine Learning Repository
- **URL:** <https://archive.ics.uci.edu/dataset/292/wholesale+customers>
- **Registros:** 440 clientes mayoristas
- **Variables:** 8 (Channel, Region, Fresh, Milk, Grocery, Frozen, Detergents_Paper, Delicassen)
- **Periodo:** Datos anonimizados de clientes de un distribuidor

4. Paso 2: Importación y exploración

4.1 Dimensiones

- **440 filas × 8 columnas**
- Sin valores nulos 
- Sin duplicados 

4.2 Estadísticas descriptivas

Variable	Media	Desv. Est.	Máximo
Fresh	12.000,30	12.647,33	112.151
Milk	5.796,43	7.384,85	73.400

Variable	Media	Desv. Est.	Máximo
Grocery	7.950,79	9.503,20	92.780
Frozen	3.071,93	4.854,67	60.869
Detergents_Paper	2.881,49	4.767,85	40.827
Delicassen	1.524,87	2.820,11	47.943

Observación: la desviación estándar > media en todas las variables → alta dispersión y posibles outliers.

4.3 Variables categóricas

- **Channel:** 298 Horeca (67,7%) / 142 Retail (32,3%)
- **Region:** 316 Other (71,8%) / 77 Lisbon / 47 Oporto

4.4 Figuras

- `01_distribucion_variables.png` — Histogramas de las 6 variables de gasto.
- `02_matriz_correlacion.png` — Correlaciones entre variables.
- `03_boxplots_por_canal.png` — Distribución de gasto por canal.

5. Paso 3: Preparación de datos

5.1 Detección de outliers (IQR)

Variable	N_outliers	%_outliers
Fresh	20	4,55%
Milk	28	6,36%
Grocery	24	5,45%
Frozen	43	9,77%
Detergents_Paper	30	6,82%
Delicassen	27	6,14%

Decisión: winsorización al percentil 99 (cap) en lugar de eliminar.

5.2 Normalización

- **StandardScaler:** media=0, std=1 (para clustering).
- **MinMaxScaler:** rango 0-1 (para visualizaciones).

5.3 Codificación

- **Region:** One-Hot Encoding (3 columnas).
- **Channel:** etiquetado como Horeca/Retail.

5.4 Dataset final

- `wholesale_preparado.csv` (440, 11)
- `wholesale_minmax.csv` (440, 8)

5.5 Figura

- `04_normalizacion_comparativa.png` — Antes/después de normalización.

6. Paso 4: Aplicación de técnicas de Data Mining

6.1 Clustering (K-means)

Selección de K:

K	Silhouette	Davies-Bouldin	Inercia
2	0.4628	1.1648	1859.12
3	0.3953	1.2471	1482.06
4	0.3106	1.1670	1241.86

K elegido: 3 (por interpretabilidad de negocio).

Resultados:

Cluster	Clientes	%	Perfil
0	64	14,55%	Fresh alto + Frozen alto
1	61	13,86%	Grocery alto + Detergents alto
2	315	71,59%	Valores bajos (pequeños)

Figuras: `05_seleccion_k.png`, `06_clusters_scatter.png`, `07_perfil_clusters.png`.

6.2 Clasificación (Árbol de decisión)

Objetivo: predecir `Channel` a partir de las 6 categorías de gasto.

Resultados:

Métrica	Train	Test
Accuracy	0.9643	0.9470
Precision	—	0.9468
Recall	—	0.9470
F1-score	—	0.9468
CV (5-fold)	—	0.8932 ± 0.0245

Importancia de variables:

Variable	Importancia
Detergents_Paper	79,56%
Milk	6,63%
Fresh	5,61%
Grocery	3,74%
Frozen	2,86%
Delicassen	1,60%

Figuras: 08_arbol_decision.png, 09_matriz_confusion.png, 10_importancia_variables.png.

6.3 Regresión (Regresión lineal)

Objetivo: predecir **Grocery** a partir de otras categorías.

Resultados:

Métrica	Train	Test
R ²	0.9020	0.7797
RMSE	3.283,47	3.046,52
MAE	2.033,66	2.057,59
CV R ²	—	0.8289 ± 0.0612

Coeficientes:

Variable	Coeficiente
Detergents_Paper	+1.6949
Delicassen	+0.2274

Variable	Coeficiente
Milk	+0.1548
Frozen	+0.0494
Fresh	+0.0406

Figuras: 11_regresion_real_vs_predicho.png, 12_analisis_residuos.png, 13_coeficientes_regresion.png.

7. Paso 5: Evaluación de modelos

7.1 Resumen comparativo

Técnica	Métrica principal	Valor	Interpretación
Clustering	Silhouette	0.3953	Clusters moderadamente separados
Clasificación	F1-score	0.9468	Excelente clasificación
Regresión	R ²	0.7797	Buena predicción

7.2 Ajustes aplicados

- **Clustering:** K=3 elegido por interpretabilidad (aunque K=2 tenía mejor métrica).
- **Clasificación:** max_depth=4 para evitar overfitting.
- **Regresión:** sin regularización (los coeficientes son interpretables).

7.3 Figura

- 14_comparativa_modelos.png — Comparativa visual de los 3 modelos.

8. Paso 6: Interpretación y visualización

8.1 Interpretación de clusters

Cluster	Nombre de negocio	Estrategia
0	"Restaurantes / Asadores"	Promociones de carne y congelados
1	"Tiendas de alimentación"	Cross-selling de lácteos y limpieza
2	"Clientes pequeños"	Campañas de reactivación y fidelización

8.2 Interpretación de clasificación

El modelo clasifica correctamente el **94,7%** de los canales. Detergents_Paper es la variable clave:

- Los **Retail** (supermercados) compran mucho detergente.
- Los **Horeca** (restaurantes) compran poca cantidad.

8.3 Interpretación de regresión

El gasto en `Grocery` se predice muy bien por `Detergents_Paper`. Cada unidad extra de detergente se asocia con **1,69 unidades extra de Grocery**.

9. Conclusiones y recomendaciones

9.1 Conclusiones

1. **3 segmentos claros** de clientes mayoristas identificados.
2. **71,6% de clientes** son pequeños y aportan poco valor → oportunidad de crecimiento.
3. **Detergents_Paper** es la variable más informativa para clasificar clientes.
4. **El modelo de clasificación es muy preciso** ($F1 = 0.9468$).

9.2 Recomendaciones para Dataclysm

1. **Segmentación personalizada:** campañas diferenciadas por cluster.
2. **Foco en clientes pequeños:** representan el 71,6% pero aportan poco → oportunidad.
3. **Detección automática de canal:** usar el árbol de decisión para clasificar clientes nuevos.
4. **Predicción de gasto:** usar la regresión para estimar ventas futuras.

10. Anexos

Anexo A: Estructura del proyecto

```
Reto8_DataMining/  
├── datos/  
│   ├── raw/  
│   └── limpios/  
├── scripts/  
│   ├── 01_exploracion.py  
│   ├── 02_preparacion.py  
│   ├── 03_clustering.py  
│   ├── 04_clasificacion.py  
│   ├── 05_regresion.py  
│   └── 06_evaluacion.py  
├── modelos/  
│   ├── modelo_clustering_kmeans.pkl  
│   ├── modelo_clasificacion_tree.pkl  
│   └── modelo_regresion_lineal.pkl  
├── salidas/  
│   ├── figuras/          (14 PNG)  
│   └── resultados/       (varios CSV)
```

Anexo B: Tecnologías

Herramienta	Versión
Python	3.13
pandas	3.0.5
scikit-learn	última
matplotlib	3.11.2
seaborn	0.13.2

FIN DEL INFORME

Documento generado por Judit Giravent — 09/2026