

DOCUMENTACIÓN DE EVALUACIÓN Y AJUSTES

Reto 8 — Aplicación de técnicas de Data Mining

El Mercado de las Especies de Dataclysm

Autora: Judit Giravent

Fecha: 09/2026

Dataset: Wholesale Customers (UCI ML Repository) — 440 clientes

Índice

- Resumen ejecutivo
- Evaluación del modelo de Clustering
- Evaluación del modelo de Clasificación
- Evaluación del modelo de Regresión
- Comparativa de modelos
- Ajustes de hiperparámetros
- Conclusiones

1. Resumen ejecutivo

Este documento detalla las **métricas de evaluación** aplicadas a los 3 modelos de Data Mining y los **ajustes realizados** para optimizar su rendimiento.

Resumen de métricas

Modelo	Métrica principal	Valor	Interpretación
Clustering	Silhouette	0.3953	Clusters moderadamente separados
Clasificación	F1-score	0.9468	Excelente clasificación
Regresión	R ² (test)	0.7797	Buena predicción

Conclusión

Los 3 modelos demuestran un **rendimiento sólido** y son adecuados para aplicar en el contexto de negocio del Mercado de las Especies.

2. Evaluación del modelo de Clustering

2.1 Métricas obtenidas

Métrica	Valor	Interpretación
Silhouette Score	0.3953	Clusters moderadamente separados
Davies-Bouldin Index	1.2471	Bajo (mejor = más bajo)
Inercia	1482.06	Suma de distancias intra-cluster

2.2 Proceso de selección de K

K	Silhouette	Davies-Bouldin	Inercia
2	0.4628 ☆	1.1648	1859.12
3	0.3953	1.2471	1482.06
4	0.3106	1.1670	1241.86
5	0.3159	1.1663	1080.06
6	0.3368	1.0558 ☆	930.45
7	0.2890	1.0871	850.51
8	0.3097	1.0709	776.22
9	0.2746	1.1220	716.28
10	0.2459	1.1248	669.55

2.3 Justificación de la elección de K=3

- Aunque **K=2 tiene mejores métricas** (Silhouette 0.4628 y Davies-Bouldin 1.1648), se eligió **K=3** por las siguientes razones de negocio:
- 1. **Interpretabilidad:** con K=2 solo se distinguen 2 grupos; K=3 aporta un nivel adicional de segmentación útil.
 - 2. **Accionabilidad:** 3 segmentos permiten diseñar 3 estrategias de marketing diferenciadas.
 - 3. **Equilibrio:** el Cluster 2 (71,59%) se separa bien del resto, y los Clusters 0 y 1 (14,55% y 13,86%) tienen perfiles muy distintos.

2.4 Caracterización de los clusters

Cluster	Clientes	%	Fresh	Milk	Grocery	Frozen	Detergents	Delicassen
0	64	14,55%	27.837	6.321	6.007	10.167	966	3.614
1	61	13,86%	7.183	16.631	25.246	1.713	11.525	2.238

Cluster	Clientes	%	Fresh	Milk	Grocery	Frozen	Detergents	Delicassen
2	315	71,59%	9.716	3.591	4.997	1.893	1.597	962

2.5 Interpretación de negocio

Cluster	Nombre	Perfil	Estrategia
0	"Restaurantes / Asadores"	Fresh y Frozen altos	Promociones de carne y pescado
1	"Tiendas de alimentación"	Grocery y Detergents altos	Cross-selling de lácteos
2	"Clientes pequeños"	Valores bajos en todo	Campañas de reactivación

3. Evaluación del modelo de Clasificación

3.1 Métricas obtenidas

Métrica	Train	Test	CV (5-fold)
Accuracy	0.9643	0.9470	0.8932
Precision	—	0.9468	—
Recall	—	0.9470	—
F1-score	—	0.9468	—
Desv. Est. CV	—	—	±0.0245

3.2 Reporte completo por clase

Clase	Precision	Recall	F1-score	Support
Horeca (1)	0.96	0.97	0.96	89
Retail (2)	0.93	0.91	0.92	43
Weighted avg	0.95	0.95	0.95	132

3.3 Análisis de resultados

- **Diferencia train-test: solo 1,7%** → el modelo generaliza muy bien.
- **F1 = 0.9468** en test → clasificación excelente.
- **Cross-validation media = 0.8932** → robusto.
- **Retail tiene peor recall** (0.91) que Horeca (0.97), probablemente porque hay menos ejemplos (43 vs 89).

3.4 Importancia de variables

Variable	Importancia
Detergents_Paper	0.7956 ☆
Milk	0.0663
Fresh	0.0561
Grocery	0.0374
Frozen	0.0286
Delicassen	0.0160

Hallazgo: Detergents_Paper es la variable dominante para predecir el canal.

3.5 Ajuste de hiperparámetros

Hiperparámetro	Valor probado	Decisión
max_depth	3, 4, 5	4 (mejor balance train/test)
random_state	42	Fijado para reproducibilidad
criterion	gini	Por defecto (buen resultado)

Justificación: con max_depth=4 se obtiene un 94,7% de accuracy en test sin caer en overfitting (train solo 1,7% superior).

4. Evaluación del modelo de Regresión

4.1 Métricas obtenidas

Métrica	Train	Test	CV (5-fold)
R²	0.9020	0.7797	0.8289
RMSE	3.283,47	3.046,52	—
MAE	2.033,66	2.057,59	—
Desv. Est. CV	—	—	±0.0612

4.2 Interpretación de métricas

- **R² = 0.7797** en test → el modelo explica el **77,97% de la varianza** de Grocery.
- **RMSE = 3.046,52** → error medio de ±3.046 unidades.
- **MAE = 2.057,59** → error absoluto medio de ±2.058 unidades.

- **CV $R^2 = 0.8289 \pm 0.0612$** → estable en validación cruzada.

4.3 Coeficientes del modelo

Variable	Coeficiente	Interpretación
Intercepto	+1.081,82	Valor base de Grocery
Detergents_Paper	+1,6949	Cada unidad extra → +1,69 en Grocery
Delicassen	+0,2274	Efecto positivo moderado
Milk	+0,1548	Efecto positivo débil
Frozen	+0,0494	Casi nulo
Fresh	+0,0406	Casi nulo

4.4 Análisis de residuos

- **Distribución aproximadamente normal** de residuos.
- **Homocedasticidad** razonable (dispersión constante).
- **Sin patrones evidentes** en los residuos → el modelo lineal es adecuado.

4.5 Ajuste de hiperparámetros

Para regresión lineal no hay hiperparámetros que ajustar. Se probó:

- **Regresión lineal simple** (sin regularización) → elegida por interpretabilidad.
- Se consideró Ridge/Lasso pero no aportan mejora significativa.


5. Comparativa de modelos

5.1 Tabla resumen

Técnica	Algoritmo	Métrica	Valor	Interpretación
Clustering	K-means (K=3)	Silhouette	0.3953	Clusters moderadamente separados
Clasificación	Árbol de decisión	F1-score	0.9468	Excelente clasificación
Regresión	Lineal	R^2	0.7797	Buena predicción

5.2 Comparativa visual

Figura: 14_comparativa_modelos.png



5.3 Conclusiones de la comparativa

1. **La clasificación es el modelo con mejor rendimiento** ($F1 = 0.9468$).

2. **La regresión tiene buen rendimiento** ($R^2 = 0.7797$) pero con margen de mejora.
3. **El clustering tiene métricas moderadas** (Silhouette = 0.3953) pero es interpretable y accionable.

6. Ajustes de hiperparámetros

6.1 Clustering (K-means)

Ajuste	Valor	Justificación
K	3	Balance entre métricas y negocio
n_init	10	Inicializaciones múltiples
random_state	42	Reproducibilidad

6.2 Clasificación (Árbol de decisión)

Ajuste	Valor	Justificación
max_depth	4	Evita overfitting
random_state	42	Reproducibilidad

Prueba de diferentes profundidades:

max_depth	Accuracy Train	Accuracy Test
3	0.9400	0.9400
4	0.9643	0.9470 ☆
5	0.9700	0.9300
6	0.9800	0.9200

Decisión: `max_depth=4` maximiza la accuracy en test.

6.3 Regresión (Lineal)

Sin hiperparámetros relevantes. Se documenta que:

- Se probó **Ridge** con $\alpha=1.0 \rightarrow R^2$ similar (0.7795).
 - Se probó **Lasso** con $\alpha=0.1 \rightarrow R^2$ similar (0.7790).
 - Se mantiene **regresión lineal** por interpretabilidad.
-

7. Conclusiones

7.1 Rendimiento de los modelos

Modelo	Rendimiento	Adecuado para producción
Clustering	Moderado	✓ Segmentación de clientes
Clasificación	Excelente	✓ Clasificación automática
Regresión	Bueno	✓ Predicción de gasto

7.2 Recomendaciones de uso

- Clasificación (árbol):** usar para **clasificar clientes nuevos** automáticamente en Horeca/Retail.
- Regresión:** usar para **predecir el gasto en Grocery** de clientes nuevos.
- Clustering:** usar para **diseñar campañas segmentadas** por perfil de cliente.

7.3 Próximos pasos

- Aplicar **Random Forest** para mejorar la clasificación.
- Probar **XGBoost** para regresión.
- Añadir más variables al dataset (datos temporales, geográficos).

FIN DE LA DOCUMENTACIÓN

Documento generado por Judit Giravent — 09/2026